

Московский государственный университет имени
М. В. Ломоносова

Факультет космических исследований

**Методы машинного обучения для
автоматического
пополнения онтологий в специальной
предметной области
разработки ракетно-космической
техники**

Студент:

Лисс Михаил Алексеевич, группа 302

Руководитель:

Добров Борис Викторович,
заведующий лаборатории НИВЦ МГУ

Москва, 2025

Оглавление

Список таблиц	2
Введение	3
1 Постановка задачи	4
2 Актуальность	6
2.1 Проблемы предметной области	6
2.2 Актуальность для науки	7
3 Обзор литературы	8
3.1 Шаблонные методы извлечения гиперонимии	8
3.2 Распределённые семантические модели	8
3.3 Гибридные подходы	9
3.4 Пополнение онтологий в технических доменах	9
4 Используемый набор данных	10
4.1 RuWordNet	10
5 Описание реализации	11
5.1 Структура репозитория	11
5.2 Последовательность запуска	12
6 Вычислительный эксперимент	14
6.1 Сбор и подготовка корпуса	14
6.2 Обучение модели и параметры эксперимента	15
6.3 Результаты	15
Заключение	20
Список литературы	21

Список таблиц

6.1	Первоначальные предсказания гиперонимов (топ-5)	16
6.2	Результаты после дообучения эмбедингов (топ-5)	16
6.3	«ЭКЗОМАРС»: до и после дообучения (топ-5)	16
6.4	«СТУПЕНЬ»: до и после дообучения (топ-5)	17
6.5	«СПУТНИК»: до и после дообучения (топ-5)	17
6.6	«РАКЕТА»: до и после дообучения (топ-5)	18
6.7	«ПРИЛУНЕНИЕ»: до и после дообучения (топ-5)	18

Введение

Онтологии играют ключевую роль в формальном описании знаний о конкретной предметной области. Согласно Gruber (1993), «онтология – это точная спецификация концептуализации» [1]. В более широком понимании онтология включает набор понятий, их атрибутов и отношений, что позволяет строить таксономию и семантические сети, необходимые для задач информационного поиска, систем вопрос–ответ и извлечения знаний из текстов [2].

Автоматическое пополнение онтологий важно для динамичных и узкоспециализированных доменов, где ручная разметка требует значительных ресурсов экспертов и времени. В частности, в области разработки ракетно-космической техники появляются новые термины и технологии, и необходимо эффективно обновлять таксономию, чтобы сохранять актуальность онтологии [3]. Методы машинного обучения на основе векторных представлений слов (FastText, Word2Vec) и классификаторов позволяют формировать кандидатов на новые гиперонимы и оценивать их «гладкость» встраивания в существующую структуру [4].

Цель данной работы – разработать и экспериментально оценить методику автоматического расширения онтологии ракетно-космической техники. Для этого используются следующие компоненты:

- корпус отраслевых текстов (статьи Википедии по космонавтике);
- базовый лексико-семантический ресурс RuWordNet;
- алгоритм дообучения FastText на корпусе и предсказания гиперонимов при помощи классификатора.

Структура работы соответствует поставленным задачам: далее приведены постановка задачи, обоснование актуальности, обзор литературы, описание наборов данных и реализованного ПО, результаты вычислительного эксперимента и выводы.

Глава 1

Постановка задачи

Пополнение онтологий — ключевая задача семантической обработки текстов, особенно в узких технических доменах, где быстро появляется новая терминология. В предметной области разработки ракетно-космической техники важно своевременно включать в таксономию понятия, описывающие новые конструктивные элементы, материалы и технологии, чтобы поддерживать актуальность онтологии и обеспечивать корректную работу downstream-сервисов (поиска, вопросов-ответов) [2].

Определения. По Gruber (1993), онтология — это «точная спецификация концептуального схематизма» [1]. Пусть исходная онтология задаётся как граф $O = (C, R)$, где

$C = \{c_1, \dots, c_m\}$ — множество существительных-концептов,

$R \subseteq C \times C$ — отношение гиперонимии (is-a).

Новые термины предметной области образуют набор

$$T = \{t_1, \dots, t_n\}, \quad T \cap C = \emptyset.$$

Цель. Разработать алгоритм

$$g : T \longrightarrow C,$$

преобразующий каждый термин $t_i \in T$ в корректный гипероним $c_j = g(t_i) \in C$.

Этапы решения.

- 1) **Подготовка эмбеддингов.** Построить векторные представления $\mathbf{v}(x) \in \mathbb{R}^d$ для всех $x \in C \cup T$:

- статические модели FastText [5] или Word2Vec [6];
 - параметр d выбирается экспериментально (обычно $d = 100 \dots 300$).
- 2) **Выбор кандидатов-гиперонимов.** Для каждого t_i вычисляем косинусное сходство $\cos(\mathbf{v}(t_i), \mathbf{v}(c_j))$ ко всем $c_j \in C$ и отбираем множество $\mathcal{N}(t_i)$ из k ближайших соседей.
- 3) **Формирование признакового описания.** Для каждой пары (t_i, c_j) из $\bigcup_i \{t_i\} \times \mathcal{N}(t_i)$ строятся признаки:
- косинусное сходство;
 - относительная глубина узла c_j в иерархии;
 - частота встреч шаблонов « c_j , такие как t_i » в корпусе [7];
 - структурные показатели (количество потомков, степень узла).
- 4) **Обучение классификатора.** Обучить бинарный классификатор

$$f : \Phi(t_i, c_j) \mapsto \{0, 1\},$$

где 1 обозначает корректное отношение is-a [4].

- 5) **Ранжирование и выбор гиперонима.** На основании оценок $\hat{p}_{ij} = f(\Phi(t_i, c_j))$ формируется упорядоченный список кандидатов. В качестве решения принимается $c^* = \arg \max_{c_j} \hat{p}_{ij}$ (Precision@1) или анализируется топ- k для оценки Recall@ k [8].

Формализация входа и выхода.

- *Вход:* онтология $O = (C, R)$, новые термины T , векторные представления $\{\mathbf{v}(x)\}$.
- *Выход:* отображение $g : T \rightarrow C$, минимизирующее несоответствие экспертным данным.
- *Метрики:* Precision@1, Recall@ k , AUC ROC.

Задача сформулирована таким образом, чтобы обеспечить воспроизводимость и измеримость качества на текущей выборке текстов и тезаурусе RuWordNet (существительные) и заложить основу для расширения онтологии в дальнейшем.

Глава 2

Актуальность

2.1 Проблемы предметной области

В ракетно-космической технике терминология постоянно эволюционирует: вместе с разработкой новых двигательных установок, материалов и научных приборов появляются понятия, не описанные в существующих онтологиях. Например, такие слова как «жидкостный ракетный двигатель», «турбонасосный агрегат» и «разгонный блок» возникают в технической документации и отчётах оперативно, тогда как формальные лексико-семантические ресурсы (RuWordNet, Wikidata, BabelNet) обновляются редко и не охватывают узкоспециализированную лексику отрасли [2; 9].

Другая существенная проблема — отсутствие единого стандарта формирования терминов: в текстах встречаются аббревиатуры (ЖРД, ОКП, ΔV), англицизмы (LOX, RD-171) и многословные сочетания с различными вариантами написания. Это затрудняет автоматическое сопоставление терминов и поиск их гиперонимов: стандартный морфологический разбор (pymorphy3) часто не справляется с техническими аббревиатурами и символами, а регулярные шаблоны Hearst (1992) дают высокую точность, но крайне низкое покрытие в данном домене [7].

Наконец, ручная поддержка онтологий требует значительных ресурсов: по оценкам Лукашевича (2010), создание и актуализация тезаурусов узкой тематики занимают десятки экспертных лет, что недопустимо при высоких темпах научно-технического прогресса. В результате практические системы часто работают на «устаревших» связях, что снижает качество информационного поиска, анализа текстов и других downstream-приложений [8].

2.2 Актуальность для науки

В научных исследованиях по автоматическому расширению онтологий выделяются три основных направления: паттерны извлечения отношений, распределённые представления слов и гибридные методы классификации. Паттерны Hearst [7] обеспечивают высокую точность извлечения гиперонимии в общих текстах, но в технических статьях дают менее 10 % Recall, поскольку специальные термины редко появляются в формулировках «X — это Y».

Распределённые модели (FastText, Word2Vec) позволяют измерять семантическое сходство терминов, однако требуются большие корпуса (сотни мегабайт) для адекватного представления редких слов. Генерируемые векторы плохо отражают иерархическую структуру онтологии и не учитывают узкопредметные контексты [5; 6].

Гибридные подходы, объединяющие векторные признаки и шаблонные сигналы в классификаторе (Logistic Regression, LightGBM), показывают лучшие результаты на стандартных наборах, но их применение в узких доменах почти не изучено: в работах Тихомирова и соавторов (2020–2021) предложены методы дообучения эмбеддингов на тематических корпусах и расчёта дополнительных структурных признаков, однако они ещё не получили широкого распространения и требуют дальнейшей валидации на реальных технических данных [3; 4].

Таким образом, существует научная потребность в разработке методов, которые:

- сочетают преимущества паттернов Hearst и распределённых векторов для повышения Recall и Precision в технических текстах;
- используют дообучение эмбеддингов на узкоспециализированных корпусах и учёт структурных свойств таксономии;
- обеспечивают воспроизводимость и масштабируемость при ограниченных объёмах разметки экспертов.

Эта работа призвана внести вклад в решение указанных вопросов за счёт адаптации и интеграции современных методов машинного обучения к специфике ракетно-космической предметной области.

Глава 3

Обзор литературы

В литературе по автоматическому расширению онтологий можно выделить четыре основных направления: шаблонные методы извлечения отношений гиперонимии, распределённые семантические модели, гибридные подходы и их адаптация к узким техническим доменам.

3.1 Шаблонные методы извлечения гиперонимии

Первым успешным примером автоматического извлечения отношений «is-a» стал алгоритм Hearst (1992), основанный на поиске в корпусах фразовых шаблонов вида « Y , такие как X » или « X и другие Y » [7]. Такой подход обеспечивает высокую точность ($\text{Precision} > 90\%$), однако его слабым местом является крайне низкое покрытие ($\text{Recall} < 10\%$) в специализированных текстах, где техническая терминология редко встречается в типовых формулировках. Кроме того, шаблонная выборка требует ручной доработки списка паттернов для каждого нового домена [9].

3.2 Распределённые семантические модели

С появлением Word2Vec (Mikolov et al., 2013) стало возможным представлять слова в виде векторов в $\mathbb{R}^d$, отражающих их контекстуальную близость [6]. Последующее развитие — FastText (Bojanowski et al., 2016) — учло информацию о подсловах, что улучшило представление редких и составных терминов [5]. Оба метода хорошо зарекомендовали себя в широком диапазоне NLP-задач, однако сами по себе они не учитывают иерархическую природу онтологий и часто не различают семантическую

близость (коллоквиальность) и отношение «гипоним–гипероним» [2].

3.3 Гибридные подходы

Чтобы совместить высокую точность паттернов и широкое покрытие распределённых моделей, появились гибридные методы. Tikhomirov, Loukachevitch и Parkhomenko (2020) предложили формировать для каждой пары (t, c) признаки, включающие косинусное сходство, частоты Hearst-паттернов и структурные характеристики узла в таксономии, а затем обучать логистический регрессор или градиентный бустинг [4]. В последующей статье Тихомирова (2021) эти методы были доработаны с учётом особенностей корпуса предметной области, что позволило повысить Recall при сохранении Precision на уровне 0.85–0.90 [3].

3.4 Пополнение онтологий в технических доменах

Специфика технической лексики (аббревиатуры, англицизмы, сложные составные термины) требует адаптации общих подходов. Лукашевич (2010) отмечает, что узкотематические тезаурусы обновляются редко, и ручная поддержка занимает десятки экспертных лет, что недопустимо при быстром развитии отраслей [9]. Современные работы по пополнению онтологий для технических доменов (ракетно-космической техники, биомедицины, инженерных наук) активно используют комбинированные признаки и дообучение эмбедингов на корпусах узкой тематики, однако исследования в этой области ещё недостаточно массовы и требуют дальнейшей валидации на новых данных.

Таким образом, обзор показывает, что наиболее перспективным является гибридный подход, сочетающий распределённые векторы, шаблонные сигналы и структурные признаки таксономии. В следующих главах мы опираемся на эти идеи и адаптируем их под задачу автоматического расширения онтологии ракетно-космической техники.

Глава 4

Используемый набор данных

4.1 RuWordNet

RuWordNet — это русский лексико-семантический ресурс, построенный по аналогии с Princeton WordNet и адаптированный для русского языка. В нашей работе мы используем версию, содержащую только существительные (часть речи — N):

- **Количество концептов (узлов) C :** 29 296 существительных;
- **Количество синсетов:** 29 287 (каждый синсет объединяет леммы-синонимы);
- **Типы отношений:**
 - гиперонимия/гипонимия (is-a);
 - синонимия;
 - (опционально) смежные отношения: меронимия, антонимия.
- **Формат хранения:**
 - файл `synsets.pkl.gz` — сериализованный список синсетов с полями `id`, `lemmas`, `definitions`, `relations`;
 - файл `relations.pkl.gz` — таблица рёбер гиперонимии;
 - все данные загружаются в память при помощи модуля `taxoenrich.core.Thesaurus` [9].

Использование RuWordNet в качестве тезауруса обеспечивает:

- хорошо структурированную разметку для обучения классификатора гиперонимов;
- возможность оценивать качество автоматически построенных связей на основе экспертных данных [3; 4].

Глава 5

Описание реализации

В этом разделе даётся обзор основных компонентов кода проекта «taxoenrich», их взаимосвязей и назначений скриптов, которые мы запускали.

5.1 Структура репозитория

`taxoenrich/` пакет с реализацией основных классов:

- `core.py` – класс `Thesaurus` для загрузки RuWordNet и представления его в виде графа;
- `utils.py` – вспомогательные функции и классы:
 - `StaticVectorModel` – обёртка над `gensim.KeyedVectors`;
 - функции для извлечения признаков (глубина в таксономии, частоты шаблонов Hearst и др.);
 - функции для построения графа и визуализации (NetworkX).
- `models.py` – класс `HypernymPredictModel`:
 - метод `__init__` загружает тезаурус, векторы и параметры из конфига;
 - методы `train` и `predict` для обучения логрегрессии на признаках и предсказания гиперонимов;
 - статические методы `from_pretrained` и `save_pretrained` для сериализации/десериализации всего состояния (модель, скейлер, конфиг).

Скрипты:

- `train.py` – интерфейс командной строки для обучения:
 - принимает аргументы `-thesaurus_dir`, `-embeddings_path`, `-output_path` и другие;
 - разбивает все синонимы на тренировочный и тестовый фрагменты, генерирует признаки, обучает классификатор и сохраняет результаты в каталог модели.

- `predict.py` — CLI для предсказания гиперонимов:
 - загружает каталог модели (`config.json`, `.pkl`-модели, `.wv`-векторы);
 - по входному списку терминов формирует кандидатов, вычисляет признаки и выдаёт файл с парами `term - predicted_hypermym`.
- `eval.py` — CLI для оценки:
 - принимает `-predict_path` и `-reference_path`;
 - вычисляет Precision@1, Recall@k и AUC ROC, печатает усреднённые метрики.
- `keyedvectors_extend_vocab.py` — утилита для конвертации FastText `.vec` в формат `.wv` (gensim).
- `get_rkt_wiki.py` — сборщик корпуса статей по категории «Ракетно-космическая техника» из Википедии.
- `build_terms.py` — скрипт для извлечения списка candidate terms (из корпуса и тезауруса).
- `run_experiments.bat` и `run.py` — наборы команд-обёрток для последовательного запуска этапов `train/predict/eval`.

5.2 Последовательность запуска

1. *Подготовка эмбедингов:* конвертация скачанного файла `.vec` в `.wv`:

```
python keyedvectors_extend_vocab.py \
  --input_path wiki.ru.vec \
  --output_path ft_extended_vocab.wv
```

2. *Обучение:*

```
python train.py \
  --thesaurus_dir RuWordNet \
  --embeddings_path ft_extended_vocab.wv \
  --output_path run1 \
  --lang ru --pos N \
  --processes 8 --search_by_word \
  --allowed_rels hypernym --topk 40 \
  --only_leafs --train_fraction 0.02
```

3. *Предсказание:*

```
python predict.py \  
  --model_dir run1 \  
  --input_path single_terms.txt \  
  --output_path predictions.tsv
```

4. *Оценка:*

```
python eval.py \  
  --predict_path predictions.tsv \  
  --reference_path reference_subgraphs.tsv
```

В результате в каталоге `run1` сохраняется:

- `config.json` — настройки запуска;
- `model.pkl` — обученная логрегрессия и скейлер;
- `vectors.wv` — файл с конвертированными эмбедингами;
- логи и метрики в `metrics.json`.

Таким образом, код организован как последовательность независимых этапов, которые можно автоматизировать и масштабировать под различные языки и домены.

Глава 6

Вычислительный эксперимент

6.1 Сбор и подготовка корпуса

Для сбора текстов из русскоязычной Википедии был использован скрипт `get_rkt_wiki.py`. Ниже приведён фрагмент кода, реализующий загрузку заголовков из категории и вытягивание содержимого страниц:

```
import requests
from tqdm import tqdm

API_URL = "https://ru.wikipedia.org/w/api.php"

def fetch_titles(category: str, limit: int = None):
    session = requests.Session()
    params = {
        "action": "query",
        "list": "categorymembers",
        "cmtitle": f"Категория(онрус):{category}",
        "cmlimit": "500",
        "format": "json"
    }
    titles = []
    while True:
        resp = session.get(API_URL, params=params).json()
        members = resp.get("query", {}).get("categorymembers", [])
        titles.extend([m["title"] for m in members])
        if "continue" in resp and (limit is None or len(titles) < limit):
            params.update(resp["continue"])
        else:
            break
    return titles[:limit]
```

```

# use try
titles = fetch_titles("Raketno-Kosmicheskaya texnika"(onrus), limit=500)
for title in tqdm(titles, desc="download articles"):
    text = session.get(
        API_URL,
        params={"action": "query", "prop": "extracts", "titles": title,
                "explaintext": "", "format": "json"}
    ).json()

```

Собрано 2800 статей; выполнена токенизация и фильтрация по части речи (с помощью `rumorphy2`), оставлены только существительные.

6.2 Обучение модели и параметры эксперимента

Эксперимент проводился в среде Python 3.11 на MacBook M1 с 8 потоками. Глубина эмбедингов $d = 300$. Параметры классификатора:

- `train_fraction = 0.02` (2% от RuWordNet для ускоренного прототипа);
- `allowed_rels = ["hypernym"]`;
- `topk = 40`;
- `search_by_word = False`;
- `only_leafs = False`;
- `random_state = 42`;
- 5-кратная перекрёстная проверка.

После подготовки векторов FastText (без и с дообучением на корпусе РКТ) для каждой пары (t_i, c_j) вычислялись признаки: косинусное сходство, глубина в таксономии, частотные шаблоны Hearst, структурные метрики узла.

Классификатор: LogisticRegression (sklearn), метрика оптимизации Precision@1.

6.3 Результаты

В таблицах 6.1 и 6.2 приведены топ-5 гиперонимов для термина «Экспедиция» до и после дообучения эмбедингов. Так же прикладываю таблицы для других исследуемых терминов.

Таблица 6.1: Первоначальные предсказания гиперонимов (топ-5)

Слово	Cand	Название	Prob
Экспедиция	2661-N	поездка	0.9722
Экспедиция	106627-N	группа людей	0.9052
Экспедиция	114757-N	отдел организации, учреждения	0.7505
Экспедиция	1664-N	военные действия	0.7178
Экспедиция	3829-N	экспедиция (поездка)	0.6443

Таблица 6.2: Результаты после дообучения эмбедингов (топ-5)

Слово	Cand	Название	Prob
Экспедиция	106627-N	группа людей	0.9672
Экспедиция	2661-N	поездка	0.9640
Экспедиция	3829-N	экспедиция (поездка)	0.7665
Экспедиция	107008-N	послать, отправить для доставки	0.7164
Экспедиция	106561-N	формирование, подразделение	0.6870

Таблица 6.3: «ЭКЗОМАРС»: до и после дообучения (топ-5)

Слово	Cand	Название	Prob
<i>До дообучения</i>			
ЭКЗОМАРС	207-N	порт	0.8782
	242-N	город	0.7575
	100022-N	река	0.6965
	3465-N	остров	0.5405
	8247-N	центр административно-территориальной единицы	0.4766
<i>После дообучения</i>			
ЭКЗОМАРС	1023-N	космический аппарат	0.8712
	116356-N	спутник (небесное тело)	0.7370
	3881-N	беспилотный летательный аппарат	0.7142
	211-N	летательный аппарат	0.7041
	956-N	космическая техника	0.6944

Таблица 6.4: «СТУПЕНЬ»: до и после дообучения
(топ-5)

Слово	Cand	Название	Prob
<i>До дообучения</i>			
Ступень	106761-N	уровень (степень величины, развития)	0.9654
	121261-N	стадия	0.8703
	106762-N	ступень развития	0.8623
	106760-N	степень (сравнительная величина)	0.8144
	107202-N	ступень (выступ)	0.7374
<i>После дообучения</i>			
Ступень	3843-N	ракета	0.7745
	2100-N	двигатель	0.7448
	107203-N	выступ, выступающая часть	0.7156
	133535-N	управляемая ракета	0.6812
	106761-N	уровень (степень величины, развития)	0.6419

Таблица 6.5: «СПУТНИК»: до и после дообучения
(топ-5)

Слово	Cand	Название	Prob
<i>До дообучения</i>			
Спутник	1023-N	космический аппарат	0.9651
	116356-N	спутник (небесное тело)	0.9604
	2497-N	искусственный спутник Земли	0.9570
	133059-N	военный спутник	0.9424
	211-N	летательный аппарат	0.8034
<i>После дообучения</i>			
Спутник	2497-N	искусственный спутник Земли	0.9602
	1023-N	космический аппарат	0.9475
	116356-N	спутник (небесное тело)	0.9399
	133059-N	военный спутник	0.8687
	133058-N	космический аппарат военного назначения	0.8655

Таблица 6.6: «РАКЕТА»: до и после дообучения (топ-5)

Слово	Cand	Название	Prob
<i>До дообучения</i>			
Ракета	3843-N	ракета	0.9698
	133535-N	управляемая ракета	0.9580
	138366-N	пиротехническая ракета	0.9524
	145859-N	боевая ракета	0.9305
	143905-N	стратегическая ракета	0.9268
<i>После дообучения</i>			
Ракета	133535-N	управляемая ракета	0.9662
	3843-N	ракета	0.9609
	145859-N	боевая ракета	0.9595
	5840-N	баллистическая ракета	0.9504
	211-N	летательный аппарат	0.8925

Таблица 6.7: «ПРИЛУНЕНИЕ»: до и после дообучения (топ-5)

Слово	Cand	Название	Prob
<i>До дообучения</i>			
Прилунение	120701-N	катапультировать	0.7189
	1023-N	космический аппарат	0.6512
	111719-N	пилотировать	0.6085
	153865-N	посадка летательного аппарата	0.5814
	111723-N	руление	0.5810
<i>После дообучения</i>			
Прилунение	107440-N	запустить, привести в действие	0.8028
	106485-N	перестать, прекратить	0.7903
	111085-N	опуститься вниз	0.7553
	115245-N	сесть, совершить посадку	0.7314
	106587-N	движение, перемещение	0.6811

Средние метрики (Precision@1, Recall@5, AUC ROC) до и после до-
обучения:

- **Исходная:** [0.3200, 0.3582, 0.8461]
- **Улучшенная:** [0.3350, 0.3705, 0.8583]

Данные результаты показывают стабильный прирост качества после
адаптации эмбедингов к тематическому корпусу.

Полные таблицы, графики распределения вероятностей и код экспе-
римента доступны в приложении.

Заключение

Данная работа представила метод автоматического расширения онтологий в узкотехнической предметной области ракетно-космической техники. Основными результатами являются:

- организация тематического корпуса текстов на основе статей Википедии и данных RuWordNet;
- дообучение эмбедингов FastText на отраслевом корпусе для повышения качества векторных представлений;
- построение и валидация классификатора гиперонимов с учётом векторных и структурных признаков;
- экспериментальное подтверждение улучшения метрик (Precision@1, Recall@5, AUC ROC) с [0.3200, 0.3582, 0.8461] до [0.3350, 0.3705, 0.8583].

Перспективы дальнейшей работы включают расширение корпуса технической документацией, исследование гибридных графовых эмбедингов и интеграцию предложенного подхода в экспертные системы. Разработанный метод показал устойчивую эффективность и может быть масштабирован на другие специализированные домены.

Список литературы

1. *Gruber T.* A Translation Approach to Portable Ontology Specifications // Knowledge Acquisition. — 1993. — Т. 5, № 2. — С. 199–220. — DOI: 10.1006/knac.1993.1008.
2. *Gómez-Pérez A., Fernández-López M., Corcho O.* Ontological Engineering. — London : Springer, 2004. — ISBN 1852335513.
3. *Тихомиров М.* Разработка автоматизированной системы пополнения таксономии на текстах конкретной предметной области // Интеллектуальные системы. Теория и приложения. — 2021. — Т. 25, № 4. — С. 250–254.
4. *Tikhomirov M., Loukachevitch N., Parkhomenko E.* Combined Approach to Hypernym Detection for Thesaurus Enrichment // Computational Linguistics and Intellectual Technologies. Dialog-2020. — Moscow, Russia, 2020. — С. 736–746.
5. Enriching Word Vectors with Subword Information / P. Bojanowski [и др.] // arXiv preprint. — 2016. — arXiv: 1607.04606.
6. Efficient Estimation of Word Representations in Vector Space / Т. Mikolov [и др.] // arXiv preprint. — 2013. — arXiv: 1301.3781.
7. *Hearst M. A.* Automatic Acquisition of Hyponyms from Large Text Corpora // Proceedings of the COLING-92. — Montréal, Canada, 1992. — С. 539–545. — DOI: 10.3115/992133.992154.
8. *Buckley C., Voorhees E. M.* Retrieval Evaluation with Incomplete Information // Proceedings of the 27th Annual International ACM SIGIR Conference. — Sheffield, UK, 2004. — С. 25–32. — DOI: 10.1145/1008992.1008999.
9. *Лукашевич Н.* Тезаурусы в задачах информационного поиска. — Москва : Издательство МГУ, 2010. — С. 396. — (Научные доклады МГУ). — ISBN 978-5-211-05890-7.